Texto a SQL en español con LoRA

Qwen/Qwen2.5-Coder-1.5B-Instruct + adapter LoRA · MySQL 8.4.10 · Colab T4

Jorge Lopez · Angel Herrarte

0.6974
EX con adapter A
(validación propia, 53/76)

0.5658
EX modelo base
(mismo prompt, 43/76)

+0.1316
aporte del fine-tuning
(10/76)

Objetivo: dado el esquema de una base (SHOW CREATE TABLE con comentarios) y una pregunta en español, generar una consulta MySQL correcta por ejecución. Las cifras son sobre nuestra validación propia, no sobre la evaluación oculta.

Contrato de la entrega

```
def generar_sql(esquema: str, pregunta: str,
                ejecutar=None) -> str
```

- `config.json`: modelo base, `adapter/`, `usar_adapter: true`, semilla 2026.
- Prompt congelado v1; generación **greedy** (`do_sample=False`, 320 tokens).
- Filtro de solo lectura: una sola sentencia SELECT/WITH; cualquier otra salida se reemplaza por `SELECT 1`.
- Estrategia entregada: **directa**, 0 de 3 llamadas a `ejecutar`. Con o sin callback la salida es idéntica.
- Revisión del modelo fijada en Hugging Face (`2e1fd39`).

Límite (auditoría Colab T4 limpio)	Medido
Carga ≤ 300 s (`import solucion`)	52.94 s
≤ 30 s por pregunta	máx. 5.253 s · media 1.576 s
Determinismo (2 corridas)	40/40 idénticas
Solo lectura	40/40 SELECT/WITH
Callback	0 llamadas · mismas salidas
Petición de borrado	`SELECT 1`

Datos de entrenamiento y procedencia

3,400
pares pregunta–SQL aceptados

15
esquemas propios de 6 tablas

66
familias de plantillas

0
descartes: todos ejecutan en MySQL 8.4.10

- Por nivel: 940 fáciles · 1400 medias · 1060 difíciles. Cubren JOIN, LEFT JOIN con ceros, HAVING, subconsultas, NOT EXISTS, CTE, ventanas y fechas.
- Sintéticos, diseñados con asistencia de IA: DDL con comentarios, semillas reproducibles y plantillas en español. No se usaron datasets externos (Spider/BIRD) ni datos personales reales.
- Cada SQL se certificó ejecutándolo en MySQL 8.4.10 con `ONLY_FULL_GROUP_BY` y se contrastó con algoritmos Python independientes. 209 pares devuelven un resultado vacío válido.
- **Limitación:** hay seis topologías de llaves foráneas y los nombres son siempre en español y completos, así que la diversidad estructural es menor que el número de esquemas.

Validación propia y evaluador

- Dos esquemas reservados que no aparecen en entrenamiento: `val_biblioteca` y `val_hospital`. La partición es por esquema.
- 40 preguntas escritas por la pareja, 20 cada integrante.
- 14 fáciles (peso 1), 16 medias (peso 2) y 10 difíciles (peso 3): **peso total 76**.
- Comprobado: 0 esquemas, preguntas o SQL compartidos con el entrenamiento. Nunca se usaron para entrenar ni como few-shot.

- **EX por ejecución**, como el enunciado: comparación de resultados como multiconjunto, orden solo si se pide, redondeo a 2 decimales, columnas extra permitidas.
- Usuario MySQL temporal con solo `SELECT`, transacción `READ ONLY`, 10 s por consulta.
- Callback como el del docente: máximo 3 llamadas y 10 filas.
- Control con oráculo: las referencias dan **76/76** en cada sesión.
- Resultado por pregunta en `resultados/validacion_propia.csv`.

Baseline: modelo sin adapter

0.5658	14/14	10/16	3/10
EX ponderada (43/76)	fáciles	medias (20/32 pts)	difíciles (9/30 pts)

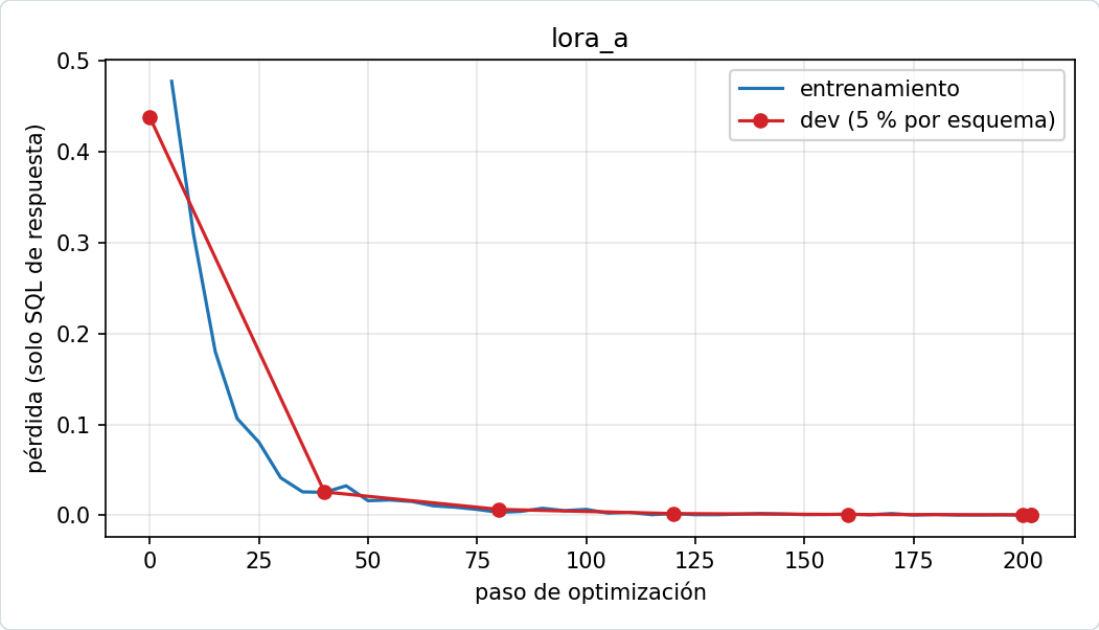
- Mismo prompt, generación y evaluador que el adapter; solo cambia `usar_adapter: false`. Determinista 40/40.
- El base resuelve bien las preguntas de una tabla y falla en las de varias tablas: 13 fallos, 6 de ellos de agregación.
- Errores típicos: `COUNT(*)` con `LEFT JOIN` (cuenta 1 en lugar de 0), `GROUP BY` rechazado por `ONLY_FULL_GROUP_BY`, columnas inventadas y una subconsulta con `LIMIT` que MySQL no admite.
- Estos patrones orientaron la hipótesis de LoRA A.

Hipótesis previas: dos LoRA que difieren en un factor

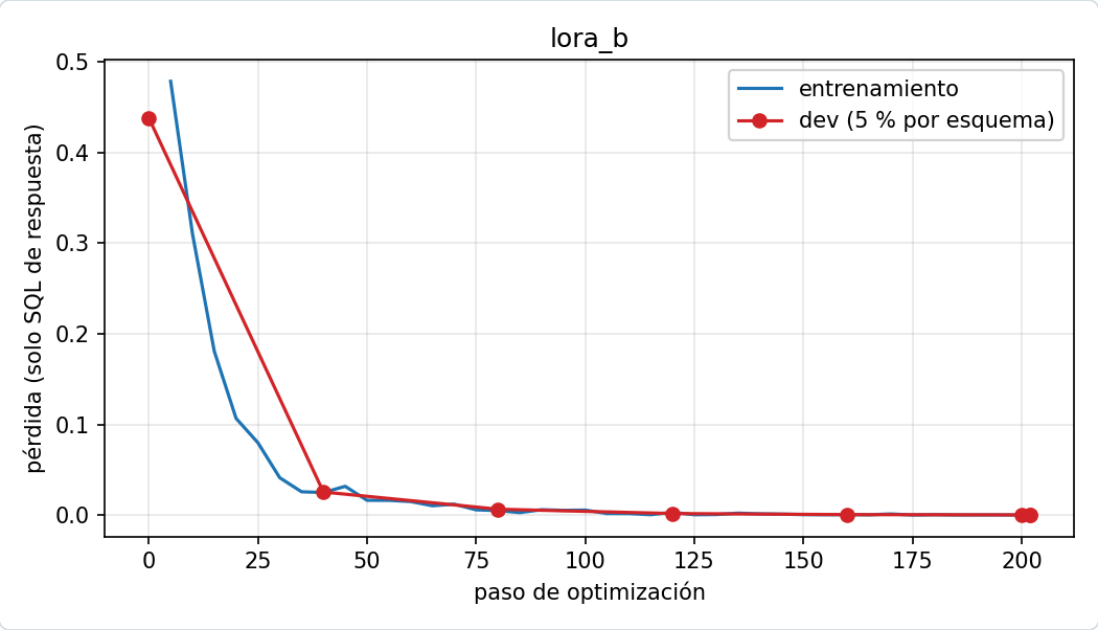
	LoRA A	LoRA B
Factor	**r = 8**	**r = 16** (único cambio; alpha/r pasa de 2 a 1)
Parámetros entrenables	9,232,384 (0.5945 %)	18,464,768 (1.182 %)
Hipótesis escrita antes de entrenar	Aprende LEFT JOIN con COUNT(col), ROW_NUMBER por grupo y GROUP BY válido: **EX ≥ 0.72**	Más capacidad mejora las consultas complejas: **EX ≥ 56/76 = 0.7368**
Resultado	0.6974: no se cumplió, aunque mejora +0.13	0.6447: no se cumplió, queda por debajo de A

Comunes: alpha 16, dropout 0.05, módulos q/k/v/o/gate/up/down · 1 época · lr 0.0002 coseno con 10 pasos de calentamiento · batch 2×8 · fp16 · pérdida solo sobre el SQL de respuesta · 3,230 ejemplos de entrenamiento y 170 de dev. Las hipótesis se publicaron en commits anteriores al entrenamiento.

Entrenamiento y curvas de pérdida



A (r=8): 2782 s en T4 · 202 pasos · pico 6.15 GiB



B (r=16): 2756 s en T4 · 202 pasos · pico 6.28 GiB

Pérdida de dev: de 0.438 a 0.0006 (A) y 0.0005 (B). Una pérdida tan baja en un dev de los mismos esquemas sugiere memorización de plantillas: B tiene menor pérdida pero peor EX, así que la pérdida no sirvió para elegir el adapter.

Comparación: base, A y B



Puntos por nivel	Base	A	B
Fácil (14)	14	14	14
Media (32)	20	24	26
Difícil (30)	9	**15**	9

- **Se entrega A** por su mayor EX y menor memoria. B gana en medias pero cae en difíciles: inventa más columnas (5 frente a 3).
- Todas las corridas son deterministas. Base y A se reprodujeron 40/40 en la auditoría final desde un Colab limpio.

Experimento de inferencia: corrección con ejecutar

Hipótesis previa: devolver al modelo el error de MySQL recupera al menos una pregunta de A. Control: generación directa. Tratamiento: hasta 3 llamadas y 2 reparaciones, con el mismo primer intento, los mismos pesos y el mismo prompt.

Configuración	EX	Latencia media	Latencia máx.	Máx. callbacks
Base · directa	43/76 · 0.5658	1.967 s	5.014 s	0
Base · corrección	48/76 · 0.6316	2.748 s	10.854 s	3
A · directa (entrega)	**53/76 · 0.6974**	**1.648 s**	**5.463 s**	**0**
A · corrección	53/76 · 0.6974	1.979 s	11.467 s	2

- La corrección recupera 2 preguntas del base (+5 puntos) y **ninguna de A**: la hipótesis no se cumple.
- Los fallos que quedan en A se ejecutan pero responden otra cosa, y el callback no detecta ese tipo de error. Con el empate se aplica la regla previa: **directa**, que además es más rápida.

Análisis de errores por categoría

Fallos (preguntas)	Sintaxis	Columna/tabla inexistente	JOIN	Agregación	Filtro	Resultado distinto	Total
Base	1	3	2	6	1	0	**13**
A (entrega)	**0**	**3**	**4**	**2**	**0**	**0**	**9**
B	0	5	4	1	0	0	**10**

- **Lo que corrige el fine-tuning:** la agregación pasa de 6 a 2 fallos (COUNT(col) con LEFT JOIN, GROUP BY válido) y desaparecen los errores de sintaxis.
- **Lo que queda en A:** relaciones indirectas. Une préstamo con título y se salta `ejemplares` (propia_07, 17, 18), o inventa `medicos.especialidad` en lugar de unir `especialidades` (propia_23).
- Ninguna configuración resuelve el promedio de conteos (propia_29) ni conservar médicos con cero pacientes (propia_35).
- Regla: si la consulta da error, manda el código MySQL. Si se ejecuta, se asigna la primera causa en el orden JOIN, agregación, filtro, resultado distinto.

Predicción de EX en la evaluación oculta

0.60
EX con adapter
rango 0.50 – 0.68

0.48
EX sin adapter
rango 0.40 – 0.56

+0.12
mejora esperada
rango +0.05 – +0.18

- **Punto de partida medido:** 0.6974, con un bootstrap del 95 % de 0.54 a 0.86 (40 preguntas, 2 esquemas).
- **Composición:** con más preguntas difíciles (peso 3), los aciertos por nivel (100 / 75 / 50 %) dan entre 0.65 y 0.67.
- **Cambio de dominio:** las bases ocultas pueden tener nombres en inglés o abreviados y de 5 a 10 tablas, cuando las nuestras tienen 6 y nombres en español. Esto afecta justo al error principal de A, el de JOIN y columnas (7 de 9 fallos).
- **Redacción:** nuestras preguntas incluyen aclaraciones, y las fechas casi no se miden en la validación.
- Es una estimación, no una medición. No esperamos llegar a 0.70.

Reproducibilidad, contribuciones y límites

Reproducibilidad

- Notebooks 01–07 (datos, baseline, LoRA A/B, experimento y auditoría). La auditoría final, en un Colab T4 limpio con solo `requirements.txt`, reprodujo base y A.
- Configuración congelada con hashes. Las corridas no se sobrescriben.
- Los resultados de Colab que se comparan se auditaron volviendo a ejecutar sus predicciones en MySQL local; en la auditoría final, 200 predicciones sin ninguna diferencia.
- Python 3.13.16 · torch 2.11.0+cu130 · transformers 5.20.2 · peft 0.18.1.

Límites

- Datos generados por plantillas y validación pequeña (40 preguntas, 2 esquemas).
- Ninguna de las tres hipótesis cuantitativas se cumplió. Se reportan tal cual.

Contribuciones

Turno	Trabajo
1 · Jorge Lopez	15 esquemas, 3,400 pares, certificación MySQL, esquemas reservados
2 · Angel Herrarte	Contrato, evaluador, baseline, hipótesis y entrenamiento de LoRA A
3 · Jorge Lopez	LoRA B, experimento de corrección, selección final
4 · Angel Herrarte	Auditoría en Colab limpio, CSV, errores, predicción, entrega
Ambos	40 preguntas de validación (20 cada uno)

Uso de IA declarado: asistencia en diseño de datos, código, revisión y redacción. Detalle en `BITACORA.md` y `CONTRIBUCIONES.md`.